


Rappels : Réseaux bayésiens



Factorisation dans un BN

$$P(X_1, \dots, X_n) = \prod_i P(X_i | \text{parents}_{X_i})$$

Inférences dans un BN

- $P(A | G = 1)$
- $P(G | A = 0)$
- $P(E | A = 0, G = 1)$
- ...




Les réseaux bayésiens dynamiques

dBN (dynamic BN)

Un réseau bayésien dynamique est un réseau bayésien dont les variables sont indicées par le temps t et par i : $X^{(t)} = X_1^{(t)}, \dots, X_N^{(t)}$ et dont la distribution vérifie certaines propriétés :

- Markov ordre 1 : $P(X^{(t)} | X^{(0)}, \dots, X^{(t-1)}) = P(X^{(t)} | X^{(t-1)})$,
- Homogénéité : $P(X^{(t)} | X^{(t-1)}) = \dots = P(X^{(1)} | X^{(0)})$.



- L'adjectif *dynamique* n'est pas forcément bien choisi (puisqu'il y a homogénéité). *Temporel* ou *séquentiel* eût été de meilleur goût.
- On remarque que d'après la définition, les arcs d'un dBN vont de $X^{(t-1)}$ à X^t ou restent dans le même X^t (le même *timeslice*).
- Formellement, un réseau bayésien dynamique peut être considéré comme virtuellement infini.
- La définition ci-dessus est celle d'un dBN du premier ordre (t ne dépend que de $t-1$). On pourrait, bien évidemment, définir des dBNs d'ordre supérieur.




Les réseaux bayésiens dynamiques (2-TBN)

2-TBN

Un réseau bayésien dynamique est défini :

- par les conditions initiales ($P(X^{(0)})$)
- par les relations entre des variables à l'instant $t-1$ et ces même variables à l'instant t (*timeslice*).

Cette représentation, appelée **2TBN** (2 timeslice BN) permet de modéliser un BN virtuellement infini qui en est le développement dans le temps, à partir d'un instant 0.




$$P(x_1^{(t)}, \dots, x_5^{(t)} | x_1^{(t-1)}, \dots, x_5^{(t-1)})$$

1024 contre $4+16+16+8+2=46$!!

$$= P(x_1^{(t)} | x_1^{(t-1)}) P(x_2^{(t)} | x_1^{(t-1)}, x_2^{(t-1)}, x_3^{(t-1)}) P(x_3^{(t)} | x_2^{(t-1)}, x_3^{(t-1)}, x_4^{(t-1)}) P(x_4^{(t)} | x_3^{(t-1)}, x_4^{(t-1)}) P(x_5^{(t)} | x_4^{(t-1)})$$



Chaîne de Markov et réseaux bayésiens dynamiques




$$P(X^n | X^{n-1}) = \begin{pmatrix} 0.25 & 0 & 0.75 \\ 0.25 & 0.25 & 0.5 \\ 0.25 & 0.5 & 0.25 \end{pmatrix}$$

Chaîne de Markov

- Une variable d'état discrète (X^n) (à l'instant n).
- Paramètres du modèle :
 - Condition initiale : $P(X^0)$
 - Modèle de transition : $P(X^n | X^{n-1})$

Réseau bayésien dynamique équivalent :




HMM et réseaux bayésiens dynamiques

HMM simple

- Une variable d'état discrète (X^n) (à l'instant n).
- Une variable d'observation discrète (Y^n)
- Paramètres du modèle :
 - Condition initiale : $P(X^0)$
 - Modèle de transition : $P(X^n | X^{n-1})$
 - Modèle d'observation : $P(Y^n | X^n)$

Ce qui donne, modélisé comme un réseau bayésien dynamique :



Inférences dans les réseaux bayésiens dynamiques


- A priori, très complexe : nombre de nœuds importants
- A priori, très complexe : "causes" communes dans un passé (lointain)

Complexité

NP-difficile

$$P(X_t^i | y_{1:r}) ?$$

- $r = t$: *Filtering*
- $r > t$: *Smoothing*
- $r < t$: *Prediction*
- MPE : *Viterbi*




Traitement des séquences

Tâches :

- Classification / Clustering
- Etiquetage / Segmentation
- Génération de séquences
- Reconnaissance de chaîne de caractères



- Reconnaissance de paroles



Traitement des séquences : *structured data*

Gene prediction

Find sequences of bases that encode proteins.

Soit $x = (x_1, \dots, x_n)$ une séquence de bases ADN ($x_i \in \{a, c, t, g\}$).


Chaque séquence x a une séquence associée de *labels*

$y = (y_1, \dots, y_n), y_i \in \{C_1, C_2\}$ (codant ou non codant).

Aron Culotta, David Kulp and Andrew McCallum. Gene Prediction with Conditional Random Fields. Technical Report UM-CS-2005-028. University of Massachusetts, Amherst, 2005.



Modèles de Markov Cachés (MMC = HMM)



- Séparation des **observations** et des **états**
 - Une chaîne = une séquence d'observations...
 - ... chaque observation ayant été générée par un état
- 2 composantes
 - Chaîne de Markov d'états finis
 - Ensemble de lois de probabilité d'émission
- 2 points de vues
 - Génératif : la chaîne génère des états qui entraînent des observations
 - Analytique : les observations fournissent de l'évidence sur la suite d'états (décodage) et sur le modèle (apprentissage)



(Possibles) Notations


- La chaîne de Markov est toujours composée de :
 - d'une séquence d'**états** $S = (s_1, \dots, s_T)$
 - dont les valeurs sont tirées dans un ensemble fini $Q = (q_1, \dots, q_N)$
 - Le modèle est toujours défini par $\{\Pi, A\}$
 - $\pi_i = P(s_1 = q_i)$
 - $a_{ij} = p(s_{t+1} = q_j | s_t = q_i)$
- Les **observations** sont modélisées à partir des s_t :
 - séquence d'observation : $X = (x_1, \dots, x_T)$
 - loi de probabilité : $b_j(t) = p(x_t | s_t = q_j)$
 - B peut être discrète ou continue
- MMC : $\lambda = \{\Pi, A, B\}$

Ce qu'on manipule

- Séquence d'observations : $X = (x_1, \dots, x_T)$
- Séquence d'états (**cachée = manquante**) : $S = (s_1, \dots, s_T)$




MMC à lois d'observation continues



La figure présente un modèle *Gauche/Droite*... Quelle est sa particularité ?



Hypothèses MMC



- CM d'ordre 1 :

$$p(s_t | s_1, \dots, s_{t-1}) = p(s_t | s_{t-1})$$

- Indépendance des observations :

$$p(x_t | x_{t-1}, s_t) = p(x_t | s_t)$$


i.e. : les observations successives sont non-corrélées !

Notations simplifiées (de a à b) :

$$s_1^t = s_1, \dots, s_t, \quad x_1^t = x_1, \dots, x_t$$



Validation...



Comment calculer probabilités suivantes ?

- Séquence d'états

$$p(s_1^T | \lambda) = p(s_1, \dots, s_T | \lambda)$$

- Séquence d'observations (connaissant les états)

$$p(x_1^T | s_1^T, \lambda)$$

- Séquences obs + états :

$$p(x_1^T, s_1^T | \lambda) = p(x_1, \dots, x_T, s_1, \dots, s_T | \lambda)$$



Point de vue génératif

Génération d'une séquence $\{x_1, \dots, x_T\}$

Data : A, B, Π

Result : x_1^T, s_1^T

```
1  $S \leftarrow [];$ 
2  $X \leftarrow [];$ 
3 Tirer  $s_1$  en fonction de  $\Pi$ ;
4 Tirer  $x_1$  en fonction de  $B$  et  $s_1$ ;
5  $s_t \leftarrow s_1, x_t \leftarrow x_1, t \leftarrow 1;$ 
6  $S \leftarrow [S, s_t], X \leftarrow [X, x_t];$ 
7 while  $s_t$  n'est pas l'état final do
8    $s_{t+1} \leftarrow$  tirage selon  $(A(s_t, :));$ 
9    $x_{t+1} \leftarrow$  tirage selon  $(B(s_{t+1}, :));$ 
10   $s_t \leftarrow s_1, x_t \leftarrow x_1;$ 
11   $S \leftarrow [S, s_t], X \leftarrow [X, x_t];$ 
12   $t \leftarrow t + 1;$ 
```




Représentation d'une trajectoire


- trajectoire d'états




- trajectoire d'observations




Représentation d'un MMC



Modélisation des pièces



2 pièces



Capacités d'expression CM, MMC

- N urnes (de Rabiner)
 - chaque urne = distribution spécifique des couleurs de boules
- On tire successivement des boules dans les différentes urnes et on note les couleurs des boules



...



$P(\text{red}) = b_1(1)$
 $P(\text{green}) = b_1(2)$
 $P(\text{yellow}) = b_1(3)$
 $P(\text{black}) = b_1(4)$
 ...
 $P(\text{orange}) = b_1(M)$

$P(\text{red}) = b_2(1)$
 $P(\text{green}) = b_2(2)$
 $P(\text{yellow}) = b_2(3)$
 $P(\text{black}) = b_2(4)$
 ...
 $P(\text{orange}) = b_2(M)$

$P(\text{red}) = b_N(1)$
 $P(\text{green}) = b_N(2)$
 $P(\text{yellow}) = b_N(3)$
 $P(\text{black}) = b_N(4)$
 ...
 $P(\text{orange}) = b_N(M)$



- Modélisation complexe
 - mixture de sources émettrices
- Problèmes de séquençage des signaux



Les trois problèmes des MMC (Fergusson - Rabiner)

- **Evaluation** : λ donné, calcul de $p(x_1^T|\lambda)$
- **Décodage** : λ donné, quelle séquence d'états a généré les observations ?

$$s_1^{T*} = \arg \max_{s_1^T} p(x_1^T|\lambda)$$

- **Apprentissage** : à partir d'une série d'observations, trouver λ^*

$$\lambda^* = \{\Pi^*, A^*, B^*\} = \arg \max_{s_1^T, \lambda} p(x_1^T|\lambda)$$



PB1 : évaluation $p(x_1^T|\lambda)$

- Quel point de départ ? [Proba totales](#)

$$p(x_1^T|\lambda) = \sum_{s_1^T} p(x_1^T, s_1^T|\lambda)$$

- Simplifier la combinatoire... [Hypothèse MMC ordre 1](#)

$$p(x_1^T|\lambda) = \sum_{s_1^T} \prod_{t=1}^T p(s_t|s_{t-1})p(x_t|s_t)$$

- Complexité ? $\mathcal{O}(N^T)$

À chaque pas de temps, envisager toutes les combinaisons d'états qui ont pu amener ici...



PB1 : évaluation $p(x_1^T|\lambda)$

Calcul par récurrence :

- On pose :

$$\alpha_t(i) = p(x_1^t, s_t = i|\lambda)$$


- Que vaut alors $p(x_1^T|\lambda)$?

$$p(x_1^T|\lambda) = \sum_{i=1}^N \alpha_T(i)$$




PB1 : Treillis

Envisager tous les états à tous les pas de temps (+ transitions) = treillis d'hypothèses



PB1 : Algorithme *forward*



$$\alpha_t(j) = p(x_1^t, s_t = j|\lambda)$$

$$\alpha_t(j) = \left[\sum_{i=1}^N \alpha_{t-1}(i) a_{ij} \right] b_j(o_t)$$

Formalisation récursive = briser la complexité



PB1 : Algorithme *forward*

- Initialisation :

$$\alpha_{t=1}(i) = p(x_1^1, s_1 = i | \lambda) = \pi_i b_i(x_1)$$

- Itération :

$$\alpha_t(j) = \left[\sum_{i=1}^N \alpha_{t-1}(i) a_{ij} \right] b_j(x_t)$$

- Terminaison :

$$p(x_1^T | \lambda) = \sum_{i=1}^N \alpha_T(i)$$

- Complexité linéaire en T
 - Usuellement : $T \gg N$



PB2 : décodage

$$s_1^{T*} = \arg \max_{s_1^T} p(x_1^T | \lambda)$$

Avec la formule précédente (hyp. MMC ordre 1) :

$$s_1^{T*} = \arg \max_{s_1^T} \prod_{t=1}^T p(s_t | s_{t-1}) p(x_t | s_t)$$

- Par défaut, très complexe
- Même schéma que précédemment = **algorithme de Viterbi**



PB2 : Viterbi

- On pose :
Meilleur score pour un chemin au temps t , se terminant à l'état i :

$$\delta_t(i) = \max_{s_1^{t-1}} p(s_1^{t-1}, s_t = i, x_1^t | \lambda)$$

A t , la probabilité du meilleur chemin est la combinaison :

- d'un des meilleurs chemins précédents...
- ... et de la transition vers s_j + observation de x_t à partir de s_j

- Initialisation :

$$\delta_1(i) = \pi_i b_i(x_1)$$

- Récurrence :

$$\delta_t(j) = \left[\max_i \delta_{t-1}(i) a_{ij} \right] b_j(x_t)$$



PB2 : Viterbi (suite)

- δ = stockage de la probabilité de certaines situations...
- Ce qui nous intéresse c'est la séquence d'états associée \Rightarrow stockage à prévoir
- Stockage des indices des états dans un tableau Ψ

$$\Psi_t(j) = \arg \max_{i \in [1, N]} \delta_{t-1}(i) a_{ij}$$

Pour arriver en j à t , quel était le meilleur état à $t - 1$???

- \Rightarrow A parcourir à l'envers pour retrouver le chemin optimal !
- Complexité en $\mathcal{O}(N^2 T)$



PB2 : Viterbi (récapitulatif)

$$\delta_t(i) = \max_{s_1^{t-1}} p(s_1^{t-1}, s_t = i, x_1^t | \lambda)$$

1 Initialisation

$$\begin{aligned} \delta_1(i) &= \pi_i b_i(x_1) \\ \Psi_1(i) &= 0 \end{aligned}$$

2 Récursion

$$\begin{aligned} \delta_t(j) &= \left[\max_i \delta_{t-1}(i) a_{ij} \right] b_j(x_t) \\ \Psi_t(j) &= \arg \max_{i \in [1, N]} \delta_{t-1}(i) a_{ij} \end{aligned}$$

3 Terminaison

$$S^* = \max_i \delta_T(i)$$

4 Chemin

$$\begin{aligned} q_T^* &= \arg \max_i \delta_T(i) \\ q_t^* &= \Psi_{t+1}(q_{t+1}^*) \end{aligned}$$

